

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN, ĐHQG - TPHCM
KHOA CÔNG NGHỆ THÔNG TIN



Đồ án 3: Data Fitting

Xây dựng mô hình dự đoán xác suất mắc bệnh tim

Học Phần: Phương pháp tính

Giảng viên hướng dẫn:

PGS.TS Nguyễn Đình Thúc

ThS Trần Hà Sơn

Lớp: 23CLC02

Sinh viên thực hiện:

23127379 – Thái Minh Huy

Ngày 14 tháng 08 năm 2025

MỤC LỤC

1	Thông tin	6
1.1.	Thông tin cá nhân	6
1.2.	Thông tin cấu hình máy tính thực hiện	6
1.3.	Những thư viện cần thiết	6
1.4.	Thông tin đồ án	7
2	Giới thiệu	9
2.1.	Mô hình hồi quy Logistic	9
2.1.1.	Dẫn nhập vấn đề	9
2.1.2.	Giới thiệu	11
2.2.	Những công cụ được sử dụng	16
2.2.1.	Công cụ sử dụng	16
2.2.2.	Những hàm được sử dụng	16
3	Mô hình đơn biến	19
3.1.	Khám phá mối liên hệ với bệnh tim	19
3.1.1.	Mối liên hệ giữa chỉ số đường huyết với bệnh tim	19
3.1.2.	Mối liên hệ giữa tuổi và bệnh tim	19
3.2.	Huấn luyện mô hình hồi quy Logistic với biến fbs	21
3.3.	Biểu thức mô hình dựa trên các hệ số ước lượng	21
3.4.	Diễn giải ý nghĩa trong ngữ cảnh mô hình	22
3.4.1.	Ý nghĩa của $e\beta_0$ trong mô hình	22
3.4.2.	Ý nghĩa của $e\beta_0 + \beta_1$ trong mô hình	22
3.5.	Tính xác suất dự đoán mắc bệnh tim	22
3.6.	Đánh giá hiệu năng của mô hình đơn biến	23
3.6.1.	Chuẩn bị siêu tham số và tiêu chí đánh giá	23
3.6.2.	Đánh giá trên tập Valid	23
3.6.3.	Đánh giá mô hình dựa trên tập Test	25
3.6.4.	Nhận xét	27

4	Mô hình đa biến	28
4.1.	Huấn luyện mô hình hồi quy Logistic sử dụng toàn bộ các biến.....	28
4.2.	Trình bày bảng hệ số hồi quy và xác định các biến có ý nghĩa thống kê	28
4.2.1.	Khi chưa chuẩn hóa z-score	29
4.2.2.	Khi chuẩn hóa z-score.....	30
4.2.3.	Nhận xét	31
4.3.	So sánh Log-Likelihood giữa mô hình đầy đủ và đơn biến	32
4.3.1.	Mô hình đa biến nhưng không chuẩn hóa z-score	32
4.3.2.	Mô hình đa biến nhưng chuẩn hóa z-score	33
4.3.3.	Nhận xét	33
4.4.	Đánh giá hiệu năng của mô hình đa biến	34
4.4.1.	Chuẩn bị siêu tham số và tiêu chí đánh giá.....	34
4.4.2.	Đánh giá trên tập Valid	34
4.4.3.	Đánh giá mô hình dựa trên tập Test.....	36
4.4.4.	Nhận xét	38
4.5.	Hạn chế của hồi quy Logistic	39
4.5.1.	Hạn chế	39
4.5.2.	Đề xuất giải pháp	39
5	Tài liệu tham khảo	40

MỤC LỤC HÌNH ẢNH

Hình 1: Đồ thị giữa mức lương, số năm kinh nghiệm và kết quả cho vay.....	10
Hình 2: Đường phân chia và dự đoán điểm mới	10
Hình 3: Đồ thị hàm Sigmoid	12
Hình 4: Ranh giới quyết định (màu xanh lam). Các giá trị trên ranh giới là dương tính, còn lại là âm tính	13
Hình 5: Đạo hàm của hàm Sigmoid	13
Hình 6: Hàm mất mát khi $y = 1$	14
Hình 7: Hàm mất mát khi $y = 0$	15
Hình 8: Biểu đồ Histogram giữa nhóm bị bệnh tim và không bị	20
Hình 9: Chỉ số AUC và ROC trên tập Valid của mô hình đơn biến	25
Hình 10: Chỉ số AUC và đường cong ROC trên tập Test	26
Hình 11: Chỉ số AUC và đường cong ROC trên tập Valid của mô hình đa biến.....	36
Hình 12: Chỉ số AUC và đường ROC của mô hình đa biến trên tập Test	37

MỤC LỤC BẢNG

Bảng 1: Thông tin cá nhân của sinh viên	6
Bảng 2: Bảng tóm tắt các thư viện sinh viên đã sử dụng	7
Bảng 3: Bảng dữ liệu về lương và thời gian làm việc	9
Bảng 4: Bảng tóm tắt các phương thức của lớp LogisticRegression	18
Bảng 5: Bảng các hàm được sử dụng	18
Bảng 6: Bảng chéo giữa chỉ số đường huyết và bệnh tim	19
Bảng 7: Thống kê mô tả giữa tuổi và bệnh tim	20
Bảng 8: Bảng chéo cho biết thực tế và dự đoán của mô hình đơn biến	24
Bảng 9: Bảng chéo dự đoán bệnh tim ở trên tập Test	26
Bảng 10: Bảng hệ số hồi quy của mô hình đa biến nếu không chuẩn hóa dữ liệu	29
Bảng 11: Bảng hệ số hồi quy khi đã chuẩn hóa dữ liệu theo phân phối chuẩn	30
Bảng 12: Bảng chéo cho biết dự đoán và thực tế của mô hình đa biến	35

1 Thông tin

1.1. Thông tin cá nhân

MSSV	Họ tên	Email
23127379	Thái Minh Huy	tmhuy23@clc.fitus.edu.vn

Bảng 1: Thông tin cá nhân của sinh viên

1.2. Thông tin cấu hình máy tính thực hiện

- OS Name: Microsoft Windows 11 Home Single Language.
- Version: 10.0.26100 Build 26100.
- Processor: 11th Gen Intel(R) Core(TM) i5-1135G7 @ 2.40GHz, 2419 MHz, 4 core (s), 8 logical Processors(s).
- RAM: 8GB.

1.3. Những thư viện cần thiết

Trong đồ án này, em có sử dụng những thư viện, phiên bản như sau:

- Python: phiên bản 3.12.0.
- Anaconda: phiên bản 3.12.7. Base Kernel sử dụng là Python 3.12.7.

Thư viện/Module	Mục đích sử dụng chính
Numpy	- Xử lý số liệu dưới dạng mảng (array), vector, ma trận. - Thực hiện các phép toán tuyến tính - Hỗ trợ tạo dữ liệu giả lập
Matplotlib.pyplot	- Thư viện biểu đồ trực quan
Panda	- Xử lý dữ liệu dạng bảng (DataFrame), dùng cho file csv và excel. - Hỗ trợ thao tác lọc, nhóm, mô tả dữ liệu.

Seaborn	- Trực quan hóa dữ liệu bằng cách vẽ biểu đồ Histogram.
Scipy.stats import norm	- Lấy phân phối chuẩn - Dùng để tính p-value các đặc trưng y học
Sklearn.metrics import train_test_split, Kfold	- Train_test_split: chia dữ liệu trong file train.csv thành 80% cho train, 20% cho tập valid. - Kfold: Thực hiện chia dữ liệu để đánh giá mô hình về độ chính xác và loss, dựa vào đó để có thể xem mô hình học tốt không.
Sklearn.metrics import roc_curve, roc_auc_score	- Roc_curve: tính các điểm FPR, TPR để vẽ đường cong ROC. - Roc_auc_score: tính chỉ số AUC (Area Under Curve), đánh giá chất lượng mô hình khi phân loại (đánh nhãn).
Typing	- Công cụ hỗ trợ gõ kiểu (type hinting). - Nhằm giúp định nghĩa rõ kiểu dữ liệu đầu vào/đầu ra của hàm/phương thức
Import statmodels.api	- Sử dụng để đối chiếu với bản tự xây dựng và bản thư viện xem đặc trưng nào có ý nghĩa thống kê và Log-likelihood (Những đoạn lệnh này được thực thi ở ô cuối cùng nhằm không gây xung đột cho tập Test của mô hình đa biến).

Bảng 2: Bảng tóm tắt các thư viện sinh viên đã sử dụng

1.4. Thông tin đồ án

Khám phá mối liên hệ giữa các chỉ số y tế và khả năng mắc bệnh tim với các thuộc tính như tuổi; giới tính; loại đau ngực; huyết áp; cholesterol, chỉ số đường huyết, điện tâm đồ, nhịp tim tối đa.

Trong đồ án này, em sẽ xây dựng mô hình hồi quy Logistic để dự đoán xác suất mắc bệnh tim dựa trên một hay nhiều đặc trưng của y học, diễn giải hệ số mô hình và tiến hành dự đoán, trực quan hóa và đánh giá hiệu năng mô hình trong việc đánh nhãn các mẫu dữ liệu trong quá trình mô hình học trên tập dữ liệu, kiểm tra và đánh giá lần cuối cùng trên tập Test được đánh sẵn ở trong một file riêng biệt.

2

Giới thiệu

2.1. Mô hình hồi quy Logistic

2.1.1. Dẫn nhập vấn đề

Ta có bài toán như sau:


Ngân hàng ABC đang làm có chương trình cho vay ưu đãi cho các đối tượng mua chung cư. Tuy nhiên gần đây có một vài chung cư rất hấp dẫn (giá tốt, vị trí đẹp,...) nên lượng hồ sơ người nộp cho chương trình ưu đãi tăng đáng kể. Bình thường thì một nhân viên có thể duyệt 10-20 hồ sơ trong một ngày để quyết định xem hồ sơ có được cho vay không, tuy nhiên số lượng hồ sơ mà nhân viên nhận được là 1000-2000 hồ sơ mỗi ngày. Nhân viên không thể xử lý hết hồ sơ. Số lượng hồ sơ nhận được quá lớn và nhân viên không thể xử lý hết được cho nên chủ tịch ngân hàng đề xuất một giải pháp là dự đoán hồ sơ mới là có nên cho vay hay không.

Sau khi phân tích thì các nhân viên đã nhận thấy là có hai yếu tố chính quyết định đến việc vay tiền đó là mức lương và thời gian công tác. Dưới đây là dữ liệu thu được:

Lương	Thời gian làm việc	Cho vay
10	1	1
9	0.5	1
5	2	1
...	...	...
8	0.1	0
6	0.3	0
7	0.15	0
...	...	...


Bảng 3: Bảng dữ liệu về lương và thời gian làm việc

Sau khi thu thập được dữ liệu, các nhân viên biểu diễn dữ liệu và tìm đường thẳng phân chia giữa các điểm cho vay và từ chối rồi quyết định hồ sơ mới có nên cho vay hay không.



Hình 1: Đồ thị giữa mức lương, số năm kinh nghiệm và kết quả cho vay

Ví dụ, đường xanh là đường phân chia. Dự đoán cho hồ sơ của người có mức lương 6 triệu và 1 năm kinh nghiệm là không cho vay.



Hình 2: Đường phân chia và dự đoán điểm mới

Tuy nhiên, do ngân hàng đang trong thời kì khó khăn nên việc cho vay bị thắt lại, chỉ những hồ sơ nào chắc chắn trên 80% mới được vay.

Vậy nên bây giờ các nhân viên không những tìm là hồ sơ ấy cho vay hay không cho vay mà cần tìm xác suất nên cho hồ sơ ấy vay là bao nhiêu.

Nếu như ta cho việc cho hồ sơ i được vay nghĩa là 1, không được vay nghĩa là 0 thì ta đang đưa bài toán này làm phân loại, dự đoán xem là hồ sơ i đó có được vay hay không.

⇒ Đây chính là bài toán phân loại, đầu ra giá trị là nhị phân (0 hoặc 1), xây dựng một mô hình nhằm dự đoán là nên (1) hay không nên (0) (Hồi quy Logistic hay Logistic Regression).

2.1.2. Giới thiệu

Hồi quy Logistic là một thuật toán được sử dụng để phân loại các quan sát theo các danh mục rời rạc. Thay vì có đầu ra là các giá trị liên tục như thuật toán hồi quy tuyến tính, hồi quy Logistic đưa đầu ra qua hàm Sigmoid để trả về một giá trị biểu thị xác suất mà quan sát đầu vào thể hiện tính chất của hai hay nhiều hơn các danh mục rời rạc. Ví dụ: email gửi đến hòm thư của người dùng có phải thư spam¹ hay không; khối u bệnh nhân đang mắc là lành tính hay ác tính,...

Dạng bài toán phân loại giá trị như trên còn có một tên gọi khác là “Phân loại nhị phân” (Binary Classification) khi mà mô hình dự đoán sẽ chỉ có hai nhãn là 0 hoặc 1.

Ứng dụng của hồi quy Logistic gồm có:

- Spam Detection: dự đoán mail gửi đến có phải spam hay không.
- Credit card fraud: dự đoán giao dịch ngân hàng có phải gian lận không.
- Banking: dự đoán khoản vay có trả được hay không.
- Investment: dự đoán khoản đầu tư vào start-up có sinh lợi hay không.

a. Hàm Sigmoid (Sigmoid Function)


Hàm Sigmoid có dạng như sau:

$$g(z) = \frac{1}{1 + e^{-z}}$$

Trong đó:

- $g(z)$: giá trị đầu ra trong khoảng từ 0 đến 1 (giá trị xác suất ước lượng).
- z : đầu vào của hàm (giá trị dự đoán của thuật toán, ví dụ như hàm $mx + b$). Tổng quát thì $z = \theta^T x$
- e : hằng số Euler và là cơ số của Logarit tự nhiên ($\ln$), giá trị của hằng số Euler là 2.718

¹ Spam (Stupid Pointless Annoying Messages): thư rác, thư có nội dung đang gây phiền phức cho người dùng



Hình 3: Đồ thị hàm Sigmoid

Hàm Sigmoid có hai đường tiệm cận ngang. Khi mà $z \rightarrow -\infty$ thì hàm $g(z)$ sẽ tiến dần về 0 và khi $z \rightarrow +\infty$ thì $g(z)$ tiến dần về 1, nếu $z = 0$ thì $g(z) = 0.5$.

Hàm Sigmoid sẽ ánh xạ bất cứ dữ liệu thực nào thành một giá trị trong khoảng từ 0 đến 1. Trong ứng dụng của học máy thì hàm Sigmoid dùng để ánh xạ các dự đoán với xác suất.


b. Ranh giới quyết định (Decision Boundary)

Hàm dự đoán của ta lúc này sẽ trả về giá trị xác suất nằm trong đoạn từ 0 đến 1. Để có thể ánh xạ xác suất này tới các danh mục rời rạc hay ta gọi là đánh nhãn mẫu thử (đúng/sai, chó/mèo,...), ta cần chọn một ngưỡng giá trị (Threshold) mà nếu xác suất lớn hơn giá trị này thì ta sẽ phân loại thành danh mục đó, còn nếu thấp hơn thì ta phân loại thành danh mục khác.

$$p \geq 0.5, label = 1$$

$$p < 0.5, label = 0$$


Ví dụ: suy đoán bệnh nhân có bị dính COVID-19 thì nếu ta có giá trị ngưỡng là 0.5 và hàm dự đoán trả về là 0.7, ta có thể phân loại điểm dữ liệu đó là dương tính (1). Nếu dự đoán là 0.2 thì ta có thể phân loại điểm dữ liệu đó là âm tính.



Hình 4: Ranh giới quyết định (màu xanh lam). Các giá trị trên ranh giới là dương tính, còn lại là âm tính

c. Hàm chi phí/Hàm mất mát (Cost/Loss Function)

Nếu như ta sử dụng hàm mất mát của hồi quy tuyến tính là MSE và khi dùng Gradient Descent trên hàm Sigmoid thì đồ thị sẽ có dạng như sau:



Hình 5: Đạo hàm của hàm Sigmoid

Vì hàm Sigmoid là một hàm phi tuyến cho nên Gradient Descent sẽ không thể cho ra được giá trị cực tiểu toàn cục (global minimum) bởi vì do có quá nhiều cực tiểu địa phương (Local minimum). Vì có quá nhiều cực tiểu địa phương nên thuật toán Gradient khó mà tìm được điểm tối ưu tại cực tiểu toàn cục.

Thay vì sử dụng MAE, ta sẽ sử dụng một hàm mất mát khác có tên gọi là Entropy chéo (Cross Entropy) hay còn được gọi là hàm mất mát Log. Hàm chi phí Entropy chéo được chia làm hai hàm chi phí riêng biệt, một hàm cho $y = 1$ và một cho $y = 0$.


$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$$

Trong đó:

$$\text{Cost}(h_{\theta}(x^{(i)}), y^{(i)}) = -\log(h_{\theta}(x)) \text{ nếu } y = 1$$

$$\text{Cost}(h_{\theta}(x^{(i)}), y^{(i)}) = -\log(1 - h_{\theta}(x)) \text{ nếu } y = 0$$

Nếu $y = 1$, ta có đồ thị của $J(\theta)$ và $h(x)$:




Hình 6: Hàm mất mát khi $y = 1$

Tính chất:

$$\text{Nếu } y = 1 \text{ và } h(x) = 1 \text{ thì } \text{Cost } J(\theta) = 0$$

$$\text{Nếu } h(x) \rightarrow 0, \text{Cost} \rightarrow \infty$$

Nếu $y = 0$, ta có đồ thị của $J(\theta)$ và $h(x)$:



Hình 7: Hàm mất mát khi $y = 0$

Tính chất:

Nếu $y = 0$ và $h(x) = 0$ thì $Cost J(\theta) = 0$

Nếu $h(x) \rightarrow 1, Cost \rightarrow \infty$

Ta có thể viết hàm mất mát mà hai trường hợp vào một biểu thức sau đây:

$$Cost(h(x), y) = -y \log(h(x)) - (1 - y) \cdot \log(1 - h(x))$$

Nếu $y = 1$ thì biểu thức $(1 - y)$ bằng 0 và không ảnh hưởng đến kết quả, tương tự nếu $y = 0$.

Ta có thể tóm gọn hàm mất mát như sau:

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m -y_i \cdot \log(h(x_i)) + (1 - y_i) \cdot \log(1 - h(x_i))$$

d. Gradient Descent

Dạng tổng quát của thuật toán Gradient Descent

$$\theta_j := \theta_j - \alpha \cdot \frac{\partial}{\partial \theta_j} J(\theta)$$

Ta còn có thể viết công thức cụ thể như sau:

$$\theta_j := \theta_j - \frac{1}{m} \cdot \alpha \cdot \sum_{i=1}^m (h(x_i) - y_i) \cdot x_{ij}$$

2.2. Những công cụ được sử dụng

2.2.1. Công cụ sử dụng

- Ngôn ngữ lập trình: Python.
- Text Editor: Visual Studio Code.
- Nền tảng: Jupyter Notebook.
- Quản lý và kiểm soát phiên bản mã nguồn (Source Control): Git và Github.
- Phương pháp lập trình: Lập trình hướng đối tượng (nhằm xây dựng mô hình hồi quy Logistics cho mô hình đơn biến và mô hình đa biến).

2.2.2. Những hàm được sử dụng

Ở mô hình đơn biến và mô hình đa biến, cả hai đều sẽ được khởi tạo thông qua một lớp có tên là LogisticRegression (lớp này là lớp em tự xây dựng dựa trên lý thuyết được giảng dạy trên lớp, không liên quan đến lớp có tên tương tự trong thư viện scikitlearn). Lớp hồi quy Logistics này em xây dựng dựa trên Gradient Descent, hàm mất mát Entropy. Lớp này sẽ có những phương thức như sau:

Tên phương thức	Tham số đầu vào	Nhiệm vụ
<code>__init__</code> (Constructor)	- α: learning_rate - <i>num_iter</i>: số vòng lặp tối đa có thể chạy. - <i>tol</i>: ngưỡng hội tụ. - <i>scale</i>: biến cờ để bật hoặc tắt chuẩn hóa dữ liệu theo z-scores	Khởi tạo mô hình, lưu lại có tham số điều chỉnh cho huấn luyện mô hình. Lưu lại hệ số θ, dữ liệu và thông tin để chuẩn hóa theo z-scores. (mean và standard_error)
Sigmoid	- <i>z</i>: giá trị đầu vào	Tính hàm Sigmoid: $\sigma(z) = \frac{1}{1+e^{-x}}$. Có thêm cơ chế chặn giá trị quá lớn hoặc quá nhỏ để tránh tràn số
<code>calculate_gradient</code>	- <i>theta</i>: vector hệ số hiện tại - <i>X_b</i>: ma trận dữ liệu nhưng có thêm cột bias. - <i>y</i>: vector nhãn	Tính Gradient của hàm mất mát theo công thức: $\theta_j := \theta_j - \frac{1}{m} \cdot \alpha \cdot \sum_{i=1}^m (h(x_i) - y_i) \cdot x_{ij}$

_scale_X	- X: ma trận đặc trưng đầu vào	Nếu scale = False, trả lại dữ liệu gốc còn nếu scale = True thì sẽ trả về dữ liệu gốc nhưng được chuẩn hóa theo z-score.
Fit	- X: ma trận đặc trưng (không có bias). - y: vector nhãn	Huấn luyện mô hình bằng Gradient Descent - Chuẩn hóa dữ liệu (nếu có bật scale). - Thêm bias vào X. - Khởi tạo $\theta = 0$. - Cập nhật θ theo Gradient Descent đến khi hội tụ hoặc đạt đến số vòng lặp tối đa.
predict_proba	- X: ma trận đặc trưng	Trả về xác suất dự đoán cho mỗi mẫu thử
predict	- X: ma trận đặc trưng - Threshold: ngưỡng phân loại (mặc định 0.5)	Trả về nhãn dự đoán (0/1) dựa trên xác suất được tính từ phương thức <code>predict_proba</code> , nếu xác suất của mẫu lớn hơn ngưỡng thì đánh nhãn 1, ngược lại là 0.
loss	- X: ma trận đặc trưng - Y: vector nhãn	Tính hàm mất mát loss: $-\frac{1}{m} \sum y \log(p) + (1 - y) \log(1 - p)$. Có thêm <i>epsilon</i> để tránh $\log(0)$.
Score	- X: ma trận đặc trưng - Y: vector nhãn	Tính độ chính xác = tỷ lệ dự đoán đúng trên toàn bộ mẫu

Summary	- Feature_names: danh sách tên các đặc trưng của dữ liệu	Tạo bảng thống kê hệ số - Hệ số ước lượng θ. - Sai số chuẩn (SE) - Z-score. - p-value Giúp diễn giải mức ý nghĩa thống kê của từng đặc trưng.
----------------	--	--

Bảng 4: Bảng tóm tắt các phương thức của lớp LogisticRegression

Ngoài ra, em có sử dụng một số hàm hỗ trợ khác nằm ở ngoài class mà em đã xây dựng:

Tên phương thức	Tham số đầu vào	Nhiệm vụ
cross_validate	- model_class: lớp mô hình sẽ được huấn luyện - X: ma trận đặc trưng - y: vector nhãn - k: số lần lặp cross-validation (mặc định 5) - **model_params: bộ tham số khởi tạo cho mô hình	Thực hiện K-Fold Cross Validation: - Chia dữ liệu thành k phần bằng nhau. - Với mỗi vòng lặp, lấy 1 fold làm validation, còn lại là train. - Huấn luyện mô hình trên tập train, tính loss và accuracy trên validation. - Lưu kết quả cuối cùng, trả về mean loss, standard loss, mean accuracy, standard accuracy
log_likelihood	- Model: mô hình đã huấn luyện - X: ma trận đặc trưng - y: vector nhãn	Tính log-likelihood của dữ liệu theo hàm cross-entropy.

Bảng 5: Bảng các hàm được sử dụng

3 Mô hình đơn biến

3.1. Khám phá mối liên hệ với bệnh tim

3.1.1. Mối liên hệ giữa chỉ số đường huyết với bệnh tim

Fbs/Target	0	1
0	114	100
1	17	17

Bảng 6: Bảng chéo giữa chỉ số đường huyết và bệnh tim

Dựa theo số liệu có được từ 248 bệnh nhân có được từ trong file train.csv, ta có thể tóm tắt số liệu có được dựa theo xác suất như sau:

- Trong tổng số 248 người, có 214 người (xác suất là $\frac{214}{248} \approx 0.8629 = 86.29\%$) là thuộc nhóm những bệnh nhân có chỉ số đường huyết (fbs , $> 120mg/dl$ thì được gọi là cao và ngược lại) thấp và thuộc nhóm $fbs = 0$ trong khi đó thì có 34 người ($0.1371 = 13.71\%$) có chỉ số đường huyết cao và thuộc nhóm những người có $fbs = 1$.
- Ở những bệnh nhân thuộc nhóm $fbs = 0$ (chỉ số đường huyết thấp) thì có 114 người không bị mắc bệnh tim (xác suất là $\frac{114}{114+100} \approx 0.5327 = 53.27\%$, xác suất của người đó mắc bệnh tim biết người đó có chỉ số đường huyết thấp) và 100 người bị mắc bệnh tim (xác suất là $\frac{100}{114+100} \approx 0.4673 = 46.73\%$, xác suất người đó mắc bệnh tim biết người đó có chỉ số đường huyết thấp).
- Ở những bệnh nhân thuộc nhóm $fbs = 1$ (chỉ số đường huyết cao) thì có 17 người không bị mắc bệnh tim (50%) và 17 người bị mắc bệnh tim (50%).
- Thông qua bảng chéo giữa chỉ số đường huyết với bệnh tim và kết quả xác suất tính được theo công thức xác suất có điều kiện thì tỉ lệ giữa người bị mắc bệnh tim và không mắc bệnh tim chênh lệch không quá nhiều (46.73% và 50%).

3.1.2. Mối liên hệ giữa tuổi và bệnh tim


Target	Số lượng	Trung bình	Sai số chuẩn	GTNN	Phân vị 25%	Phân vị 50%	Phân vị 75%	GTLN
0	131	52.31	9.64	29	44.5	52	59	76
1	117	56.68	8.01	35	52	58	62	77

Bảng 7: Thống kê mô tả giữa tuổi và bệnh tim

Từ bảng số liệu thống kê mô tả ghi nhận được giữa tuổi của các bệnh nhân và bị mắc bệnh tim:

- Có 131 người không bị mắc bệnh tim và 117 người bị mắc bệnh tim.
- Về trung bình tuổi thì nhóm không bệnh có độ tuổi trung bình là 52, trong khi ở nhóm người bị mắc bệnh tim thì độ tuổi trung bình ghi nhận là 56. Điều này cho thấy bệnh tim thường xuất hiện ở những người lớn tuổi.
- Về độ lệch chuẩn thì ở nhóm người không bị mắc bệnh tim thì có độ phân tán tuổi là 9, rộng hơn so với nhóm bị mắc bệnh tim. Nghĩa là nhóm không bệnh có tuổi trải rộng hơn so với nhóm mắc bệnh.
- Từ mức phân vị của hai nhóm thì ở nhóm những người không bị mắc bệnh tim thì trải dài từ độ tuổi 44 đến 59 trong khi đó ở nhóm những người bị mắc bệnh tim thì trải từ độ tuổi 52 đến 62. Điều này cũng một phần cho thấy được rằng, đa số những ca mắc bệnh tim thường xuất hiện ở người lớn tuổi rất nhiều. Chúng ta có thể thấy được thông qua hai biểu đồ giữa hai nhóm.

Phân bố tuổi theo nhóm bệnh tim



Hình 8: Biểu đồ Histogram giữa nhóm bị bệnh tim và không bị

- Thông qua biểu đồ thứ nhất, nhóm người không bị mắc bệnh tim độ tuổi được phủ rộng, nhiều hơn và tập trung nhiều nhất ở độ tuổi 40-50. Tại biểu đồ thứ hai thì nhóm người bị bệnh tim tập trung nhiều nhất ở bên phải từ độ tuổi 50-65.
- ⇒ Tuổi cũng là một trong những đặc trưng y học có liên quan đến bệnh tim. Từ biểu đồ và bảng thống kê mô tả được ghi nhận ở trên thì nhóm bệnh tim có xu hướng lớn hơn so với nhóm không mắc bệnh. Ta có thể nhận thấy tại biểu đồ thứ hai (màu xanh) thì lệch về phía bên phải là những bệnh nhân có tuổi cao, biểu đồ thứ nhất (màu cam) thì lệch về phía trái, tập trung nhiều nhất ở tuổi thanh niên và trung niên.

3.2. Huấn luyện mô hình hồi quy Logistic với biến fbs

Tại đây, em xây dựng mô hình đơn biến thông qua thuật toán Logistic tự xây của em thông qua phương pháp Gradient Descent. Sau khi huấn luyện mô hình với đặc trưng y học là chỉ số đường huyết (fbs), ta thu được phương trình có dạng như sau:

$$p(y = 1|x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$

Công thức trên nếu diễn giải theo xác suất có điều kiện là xác suất người đó mắc bệnh tim khi chỉ số đường huyết cao hoặc thấp ($x = 0$ hoặc $x = 1$)

Trong đó:

- $\beta_0 = -0.1214$ là bias được thêm vào (Intercept).
- $\beta_1 = 0.0513$: hệ số của chỉ số đường huyết (fbs).
- x : giá trị nhận vào của biến fbs, 0 là chỉ số đường huyết thấp, 1 là chỉ số đường huyết cao.

Giải thích hệ số:

- Bias/Intercept ($\beta_0 = -0.1214$)
 - Cho biết khả năng mắc bệnh tim của bệnh nhân khi $fbs = 0$.
 - Cho biết xác suất của bệnh nhân có mắc bệnh tim hay không khi chỉ số đường huyết thấp.
- Hệ số fbs ($\beta_1 = 0.0513$)
 - Cho biết khả năng mắc bệnh tim của bệnh nhân khi $fbs = 1$.
 - Cho biết xác suất của bệnh nhân có mắc bệnh tim hay không khi chỉ số đường huyết cao.

3.3. Biểu thức mô hình dựa trên các hệ số ước lượng

Từ hệ số ước lượng mà ta tính được thì biểu thức của mô hình đơn biến với đặc trưng y học chỉ số đường huyết là:

$$p(y = 1|x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}} = \frac{1}{1 + e^{-(-0.1214 + 0.0513.fbs)}}$$

3.4. Diễn giải ý nghĩa trong ngữ cảnh mô hình

Dựa vào hệ số ước lượng và biểu thức mô hình mà ta đã có được trước đó, ta biến đổi như sau:

$$\begin{aligned} p(y = 1|x) &= \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}} = \frac{1}{1 + e^{-(-0.1214 + 0.0513.fbs)}} \\ \Leftrightarrow \ln\left(\frac{p}{1-p}\right) &= e^{-(-0.1214 + 0.0513.fbs)} \end{aligned}$$

Khi ta nói về e^{β_0} là ta đang nói về tỷ số chênh giữa nhóm người có chỉ số đường huyết cao và chỉ số đường huyết thấp.

3.4.1. Ý nghĩa của e^{β_0} trong mô hình

Khi $fbs = 0$ thì tỷ số chênh của bệnh tim là β_0 , khi này tỉ lệ mắc bệnh sẽ là:

$$Odds(y = 1 | fbs = 0) = e^{\beta_0}$$

Ý nghĩa: e^{β_0} là tỷ số chênh mắc bệnh tim khi chỉ số đường huyết thấp tương đương theo định nghĩa xác suất có điều kiện là xác suất bệnh nhân đó mắc bệnh tim khi chỉ số đường huyết thấp.

3.4.2. Ý nghĩa của $e^{\beta_0 + \beta_1}$ trong mô hình

Khi $fbs = 1$ thì tỷ số chênh của bệnh tim là $\beta_0 + \beta_1$, khi này tỉ lệ mắc bệnh sẽ là:

$$Odds(y = 1 | fbs = 1) = e^{\beta_0 + \beta_1}$$

Ý nghĩa: $e^{\beta_0 + \beta_1}$ là tỷ số chênh mắc bệnh tim khi chỉ số đường huyết cao tương đương theo định nghĩa xác suất có điều kiện là xác suất bệnh nhân đó mắc bệnh tim khi chỉ số đường huyết cao.

3.5. Tính xác suất dự đoán mắc bệnh tim

Dựa vào biểu thức mô hình ở trên thì xác suất dự đoán mắc bệnh tim là:

- Trường hợp 1: khi chỉ số đường huyết thấp, xác suất là $0.4643 = 46.43\%$.
- Trường hợp 2: khi chỉ số đường huyết cao, xác suất là $0.5000 = 50\%$.
- Kết quả này giống với kết quả mà ta tính được khi thống kê mô tả giữa chỉ số đường huyết và bệnh tim theo công thức xác suất có điều kiện.

3.6. Đánh giá hiệu năng của mô hình đơn biến

3.6.1. Chuẩn bị siêu tham số và tiêu chí đánh giá

Mô hình đơn biến sử dụng đặc trưng y học là biến fbs (chỉ số đường huyết) được xây dựng với siêu tham số như sau:

- α (learning_rate) = 0.01.
- Số lần lặp (num_iters) = 50000.
- Sai số chấp nhận được để hội tụ (tolerance) = $1e - 5 = 0.00001$.
- Mô hình đơn biến có sử dụng phân phối chuẩn (scale = True).

Mô hình sẽ được học ở trên file train.csv tuy nhiên chỉ học trên 198 mẫu (từ 1 $\rightarrow$ 198), 50 mẫu còn lại (từ 199 $\rightarrow$ 248) sẽ được dùng cho tập Valid nhằm kiểm tra hiệu năng của mô hình lần cuối trước khi cho mô hình sử dụng 50 mẫu nằm trong file test.xlsx. Mô hình sẽ được kiểm tra thông qua các tiêu chí:

- Accuracy (độ chính xác mà mô hình dự đoán với dữ liệu gốc).
- Cross-Validation (nhằm đánh giá độ thành công của mô hình và mất mát bao nhiêu).
- Confusion Matrix (phân tích xem mô hình đã dự đoán đúng bao nhiêu nhãn là khớp với nhãn gốc).
- Đường cong ROC và AUC (trực quan biểu đồ cho biết là mô hình đã dự đoán nhãn các dữ liệu là đúng hay sai nhiều hơn, có dự đoán được tổng quát, nghiêng về phía nào giữa hai nhãn đúng và sai).

3.6.2. Đánh giá trên tập Valid

Sau khi cho mô hình đơn biến học được 80% dữ liệu, kiểm tra xem là với 80% dữ liệu gốc, mô hình đã dự đoán chính xác 53.03%, mất mát là 0.6910. Đưa mô hình đó qua tập Valid thì mô hình dự đoán chính xác các nhãn là 52%, mất mát trên tập Valid là 0.6926.

Sau đó, thực hiện kiểm tra mô hình đơn biến theo KFold, kiểm tra với 10 lần khác nhau thì kết quả sai số về độ chính xác và mất mát của mô hình đơn biến là:

- CV Loss: 0.6973 ± 0.0126 .
- CV Acc: 0.5040 ± 0.0644 .

Kết quả về độ chính xác và mất mát của mô hình đơn biến trên hai tập là Train với Valid đều ở trong phạm vi của CV Acc và CV Loss cũng chứng tỏ mô hình đơn biến với đặc trưng y học là chỉ số đường huyết của em xây dựng có thể học tổng quát, không phải là chỉ

thuộc Pattern để phân tích và dự đoán, cũng cho thấy được là mô hình không bị tình trạng Overfitting (Quá khớp) và nhận diện các mẫu tốt.

Tuy nhiên, chỉ với độ chính xác về dự đoán thì không phải là tiêu chí chính xác mà ta sẽ xem là trên tập Valid, mô hình đã thực sự dự đoán như thế nào thông qua Confusion Matrix. Trên tập Valid thì mô hình đã dự đoán như sau, lớp bị bệnh tim được chẩn đoán là Positive và lớp không bị bệnh tim là Negative.

Thực tế/Dự đoán	Có bệnh (1)	Không bệnh (0)
Có bệnh (1)	2 (True Positive)	22 (False Negative)
Không bệnh (0)	2 (False Positive)	24 (True Negative)


Bảng 8: Bảng chéo cho biết thực tế và dự đoán của mô hình đơn biến

Trong đó:

- True Positive = 2: thực tế là có bệnh và dự đoán cũng là có bệnh.
- False Positive = 2: thực tế là không bệnh nhưng dự đoán là có bệnh. (sai lầm loại I).
- False Negative = 22: thực tế có bệnh nhưng dự đoán là không bệnh. (sai lầm loại II).
- True Negative = 24: thực tế không bệnh và dự đoán không bệnh.
- Mô hình dự đoán đúng là $2 + 24 = 26$ bệnh nhân, tỉ lệ thành công là 52%
- Trong việc dự đoán có bệnh thì $\text{Precision} = \frac{2}{2+2} = 50\%$, $\text{Recall} = \frac{2}{2+22} = 0.083 = 8.3\%$.

Dù mô hình có Precision ở mức trung bình nhưng Recall của mô hình có điểm rất thấp cho nên F-score của mô hình là 0.1429, chỉ số F-score này là rất thấp, chứng minh cho thấy được mô hình đơn biến nhưng nếu chỉ dùng đặc trưng là chỉ số đường huyết thì việc dự đoán số người bệnh tim là chưa đầy đủ, ta có thể thấy là trong 50 tập của Valid thì mô hình chỉ có Accuracy là trung bình, tỉ lệ này gần với việc mô hình đoán ngẫu nhiên dựa một trong hai lựa chọn.

Cuối cùng là chỉ số AUC và ROC của mô hình đơn biến thì ta có thể từ biểu đồ quan sát ở dưới đây:



Hình 9: Chỉ số AUC và ROC trên tập Valid của mô hình đơn biến

Chỉ số $AUC = 0.5032$ và ta có thể chỉ số này gần xấp xỉ với đường đứt nét đại diện cho việc đoán ngẫu nhiên thì mô hình đơn biến nhưng chỉ dùng đặc trưng chỉ số đường huyết dự đoán không chính xác và dự đoán của mô hình dựa hoàn toàn vào ngẫu nhiên và điều đó cũng hoàn toàn chứng minh được là mô hình đơn biến nhưng dùng fbs là một mô hình chưa thực sự tốt để có thể làm mô hình dự đoán, vẫn còn mang tính ngẫu nhiên. Vì thế nên để có thể phân loại bệnh nhân tốt thì ta phải kết hợp nhiều đặc trưng lại để có thể phân tích và dự đoán chính xác được.

3.6.3. Đánh giá mô hình dựa trên tập Test

Khi ta sử dụng mô hình đơn biến này trên tập Test thì ta có những kết quả như sau:

- Accuracy: $0.5200 = 52\%$
 - Loss: 0.6866
- ⇒ So sánh với Cross-Validation KFold về Accuracy và Loss thì ta thấy mô hình không bị Overfitting khi hoạt động ở trên tập Test.

Xét tới Confusion Matrix thì ta có bảng chéo dự đoán của mô hình như sau:


Thực tế/Dự đoán	Có bệnh (1)	Không bệnh (0)
Có bệnh (1)	3 (True Positive)	17 (False Negative)
Không bệnh (0)	7 (False Positive)	23 (True Negative)

Bảng 9: Bảng chéo dự đoán bệnh tim ở trên tập Test

Trong đó:

- True Positive = 3: thực tế là có bệnh và dự đoán cũng là có bệnh.
- False Positive = 7: thực tế là không bệnh nhưng dự đoán là có bệnh. (sai lầm loại I).
- False Negative = 17: thực tế có bệnh nhưng dự đoán là không bệnh. (sai lầm loại II).
- True Negative = 23: thực tế không bệnh và dự đoán không bệnh.
- Mô hình dự đoán đúng là $3 + 23 = 26$ bệnh nhân, tỉ lệ thành công là 52%
- Trong việc dự đoán có bệnh thì Precision = 0.3, Recall = 0.15.

Khi hoạt động ở trên tập Test, Precision và Recall của mô hình đơn biến trả về kết quả dưới trung bình và điểm không cao dẫn đến F1-score của mô hình điểm cũng thấp, giá trị là 0.2. Điều này đã chứng minh cho thấy được một điều, mô hình đơn biến không phải là một mô hình có thể dự đoán tốt, tỉ lệ mô hình dự đoán hoàn toàn có bệnh là chỉ có 3 người, một con số khiêm tốn cho thấy mô hình với chỉ số đường huyết là chưa đủ mạnh để ứng dụng vào dự đoán.



Hình 10: Chỉ số AUC và đường cong ROC trên tập Test

Từ kết quả so với Valid thì dù điểm Precision và Recall cao hơn nhưng khi mà xét tới chỉ số AUC thì AUC có giá trị là 0.4583, lần này thì đường cong ROC ở dưới đường nét gạch hoàn toàn, dường như là mô hình dự đoán không có bệnh lại nhiều hơn khi mà chỉ số đã lệch về bên trái rất nhiều, dự đoán hoàn toàn có bệnh dù có nhưng không ảnh hưởng lên biểu đồ vì đa số là mô hình dự đoán không bệnh là nhiều hơn so với có bệnh.

3.6.4. Nhận xét

Mô hình đơn biến là một mô hình tuy đơn giản và có thể sử dụng một cách dễ dàng tuy nhiên nếu ta chỉ sử dụng một đặc trưng nhằm dự đoán, đánh nhãn cho dữ liệu sau này thì mô hình này không phải là một mô hình mang tính chiến lược tốt, đặc biệt là ở trong ngữ cảnh bài toán này là sử dụng chỉ số đường huyết chỉ có giá trị là 0 hoặc 1 thì mô hình đơn biến dự đoán tạo cảm giác là ngẫu nhiên nhiều hơn. Chính vì thế, để có thể dự đoán được tốt và chính xác cao hơn thì ta phải sử dụng mô hình đa biến và kết hợp với nhiều đặc trưng khác nhau để có thể dự đoán tốt hơn, có thể sử dụng mô hình đa biến trong những kế hoạch chiến lược.

4 Mô hình đa biến

4.1. Huấn luyện mô hình hồi quy Logistic sử dụng toàn bộ các biến

Đối với mô hình đa biến, em cũng dùng chính class mà em đã tự xây dựng để có thể huấn luyện mô hình hồi quy Logistic nhưng lần này là sẽ sử dụng tất cả 13 đặc trưng của y học để xây dựng các hệ số hồi quy cho mô hình. Sau khi huấn luyện mô hình với tất cả đặc trưng y học thì ta sẽ thu được phương trình tổng quát có dạng như sau:

$$p(y = 1 | x) = \frac{1}{1 + e^{-(\beta_0 + \sum_{i=1}^{13} \beta_i x_i)}}$$

Trong đó:

- $\beta_0 = -0.0508$ là bias(intercept) được thêm vào
- β_i là các hệ số ứng với một đặc trưng (từ age $\rightarrow$ thal)
- Hệ số ước lượng của mô hình hồi quy lần lượt là: (0.0362, 0.5808, 0.6381, 0.6233, 0.0147, -0.1809, 0.0561, -0.4327, 0.4356, 0.4854, 0.1959, 0.8867, 0.5708).
- x_i : các giá trị của các đặc trưng khi ta thế các giá trị của một mẫu hay những số liệu ghi nhận được từ các bệnh nhân nhằm dự đoán bệnh nhân đó có bị bệnh tim không.

Các hệ số ước lượng của mô hình hồi quy này đã được bật cờ *scale = True* để có thể đưa các giá trị của các đặc trưng y học về phân phối chuẩn để có thể dễ tính toán, mô hình có thể tính toán trên những hệ số nhỏ hơn, học tốt hơn.

4.2. Trình bày bảng hệ số hồi quy và xác định các biến có ý nghĩa thống kê

Tại câu hỏi bài tập này, em có phân chia thành hai trường hợp mà em đã gặp trong quá trình em huấn luyện mô hình đa biến, bảng hệ số hồi quy là em không sử dụng thư viện bên ngoài để thực hiện mà tự xây dựng thành một phương thức riêng ở trong class LogisticRegression, thư viện đó em có sử dụng nhằm để so sánh các hệ số, *p - value* mà em tính được so với thư viện có gì khác biệt hay không và dựa vào đó để có thể tùy chỉnh và đưa ra nhận xét của hai trường hợp. Phần này chủ yếu để trình bày các hệ số hồi quy, không phải dùng để Test cho nên sẽ tính toán trên 248 mẫu dữ liệu.

4.2.1. Khi chưa chuẩn hóa z-score

Đặc trưng	Hệ số	Sai số chuẩn	z	p-value
Intercept	-0.585091	868.672027	-0.000674	0.999463
age	-3.036841	38.673646	-0.078525	0.937411
sex	12.946768	94.380999	0.137176	0.890892
cp	23.790383	145.140741	0.163913	0.869800
trestbps	0.665868	3.701055	0.179913	0.857221
chol	0.012921	0.604558	0.021372	0.982949
fbs	-2.803879	485.259769	-0.005778	0.995390
restecg	6.476366	49.292419	0.131387	0.895469
thalach	-1.321574	12.375853	-0.106787	0.914958
exang	15.703452	157.878002	0.099466	0.920768
oldpeak	24.222309	140.091445	0.172904	0.862727
slope	5.713746	131.436306	0.043472	0.965326
ca	41.843286	578.067099	0.072385	0.942296
thal	27.988738	306.269972	0.091386	0.927186

Bảng 10: Bảng hệ số hồi quy của mô hình đa biến nếu không chuẩn hóa dữ liệu

Trong 14 hệ số ước lượng, ta bỏ đi hệ số Bias/Intercept để xét 13 đặc trưng còn lại. Xét 13 đặc trưng y học thì $p - value$ của tất cả đặc trưng đều có giá trị p-value đều tiến gần đến 1, không đặc trưng nào có $p - value < 0.05$ theo yêu cầu. Điều đó có nghĩa là tất cả 13 đặc trưng y học mà ta tính được lại không có ý nghĩa thống kê, nếu như ta cần tìm hiểu xem đặc trưng có ý nghĩa thống kê thì ta sẽ khó nhận biết được đặc trưng nào sẽ có liên quan đến việc dự đoán.

Ngoài ra, ta có thể thấy, các hệ số và sai số của các đặc trưng y học lại rất lớn. Điều này ảnh hưởng đến quá trình học của mô hình khi mà một vài đặc trưng lại quá lớn và một số

đặc trưng lại quá nhỏ và thuật toán Gradient Descent sẽ đi theo những đặc trưng lớn có phạm vi rộng mà không để ý gì đến những đặc trưng nhỏ khác.

4.2.2. Khi chuẩn hóa z-score

Đặc trưng	Hệ số	Sai số	z	p-value
Intercept	-0.004026	0.201677	-0.019963	0.984073
age	-0.210335	0.234288	-0.897764	0.369311
sex	0.609197	0.246195	2.474453	0.013344
cp	0.526748	0.205486	2.563421	0.010365
trestbps	0.605187	0.214384	2.822905	0.004759
chol	0.159724	0.213635	0.747646	0.454673
fbs	-0.273965	0.217505	-1.259576	0.207822
restecg	0.065810	0.203118	0.323998	0.745940
thalach	-0.536089	0.256877	-2.086947	0.036893
exang	0.459803	0.213190	2.156772	0.031023
oldpeak	0.322744	0.279079	1.156459	0.247493
slope	0.272768	0.246003	1.108799	0.267517
ca	1.156641	0.267824	4.318658	0.000016
thal	0.621587	0.212356	2.927103	0.003421

Bảng 11: Bảng hệ số hồi quy khi đã chuẩn hóa dữ liệu theo phân phối chuẩn

Tương tự như trên, ta vẫn bỏ đi hệ số Bias và chỉ xét đến 13 đặc trưng còn lại. Ta có thể nhận ra là các hệ số ước lượng của 13 đặc trưng y học lần này đã nhỏ đi hơn rất nhiều so với việc ta không chuẩn hóa dữ liệu. Nhờ việc chuẩn hóa dữ liệu cho nên sai số của các hệ số ước lượng cũng đã nhỏ hơn và tất nhiên mọi thứ nhỏ đi nghĩa là mô hình có thể học tốt hơn, dễ tính toán và sẽ không bị lệ thuộc vào một đặc trưng nào. Các đặc trưng đều đã được quy chuẩn về một khoảng phù hợp để cho mô hình học tổng quan hơn.

Ngoài ra, việc hệ số và sai số của các đặc trưng nhỏ đi cũng đã giúp cho chúng ta rất nhiều đó là $p - value$ của các đặc trưng đã rõ ràng hơn, không có bị trường hợp mà tất cả đặc trưng đều tiến gần đến 1. $p - value$ nhỏ hơn cũng giúp cho chúng ta có thể nhận ra đặc trưng nào có ý nghĩa thống kê:

- sex: giới tính của bệnh nhân.
- cp: loại đau ngực.
- trestbps: huyết áp lúc nghỉ.
- thalach: nhịp tim tối đa.
- exang: có đau ngực khi gắng sức.
- ca: Số mạch chính được nhuộm màu.
- thal: loại bệnh Thalassemia.

Sau khi nhận được kết quả như trên thì em đã có sử dụng thư viện có sẵn từ statsmodels.api để đối chiếu thì cũng ra những đặc trưng em đề cập ở trên là có ý nghĩa thống kê.

4.2.3. Nhận xét

Thông qua quá trình em huấn luyện và kiểm tra về bảng hệ số hồi quy, kiểm tra so với bản thư viện đã được tối ưu sẵn thì em thấy khi huấn luyện mô hình hồi quy, đặc biệt khi mà chúng ta huấn luyện mô hình với nhiều đặc trưng, đó là chúng ta cần phải có một bước là chuẩn hóa các dữ liệu về một dạng chung để cho mô hình có thể học được dễ dàng hơn.

Như ta thấy từ hai trường hợp của bảng hồi quy các hệ số ước lượng, tại trường hợp mà ta không chuẩn hóa dữ liệu thì hệ số và sai số của các đặc trưng lại quá lớn dẫn đến $p - value$ của các đặc trưng hầu như đều tiến gần đến 1. Chúng ta còn không thể nhận xét được đặc trưng nào thực sự là đặc trưng có ý nghĩa thống kê trong ngữ cảnh của mô hình. Việc sai số quá lớn còn gây ra hệ quả đó là mô hình sẽ đi theo một đặc trưng nhất định nào đó để có thể học mà bỏ qua những đặc trưng khác như là đặc trưng có tính phân loại như giới tính, loại đau ngực. Ngoài ra, việc không chuẩn hóa còn có thể dẫn đến đó là Gradient Descent sẽ hội tụ khó khăn hơn, ta có thể điều chỉnh siêu tham số (Hyper-parameters) để thực hiện điều đó nhưng ta lại phải đánh đổi đó là mô hình học sẽ rất chậm và hệ số sẽ càng lớn hơn khiến việc dự đoán để đánh nhãn dữ liệu không thực sự là tốt.

Đối với trường hợp của bảng hồi quy số hai là em đã dùng phương pháp chuẩn hóa tất cả các đặc trưng y học theo phân phối chuẩn (z-score) thì kết quả trả về tốt hơn so với việc ta phải dùng tất cả các dữ liệu gốc của đặc trưng. Các hệ số hồi quy mà ta ước lượng, sai số nhỏ hơn rất là nhiều so với không chuẩn hóa và $p - value$ của các đặc trưng được thể hiện tốt hơn so với trường hợp một. Ta có thể biết được là đặc trưng nào sẽ có ý nghĩa thống kê trong mô hình.

Việc chuẩn hóa dữ liệu có những điểm lợi như sau:

- Khi ta chuẩn hóa các dữ liệu về cùng một kiểu, ta đang giúp cho mô hình hội tụ nhanh hơn trong quá trình huấn luyện. Nghĩa là nếu như mà ta không hề chuẩn hóa dữ liệu trước thì mô hình sẽ khó mà có thể hội tụ được, việc hội tụ vẫn có thể xảy ra nhưng đổi lại thì thời gian thực thi sẽ rất lâu và việc dự đoán của mô hình có thể không chính xác.
- Giúp mô hình có thể suy luận nhằm đưa ra dự đoán chính xác hơn vì khi mà mọi đặc trưng có quá nhiều phạm vi khác nhau, mô hình kết quả có thể đưa ra kết quả sai.
- Giúp cho mô hình có thể sử dụng các hệ số phù hợp vì nếu như mà ta không điều chỉnh dữ liệu về một kiểu thì mô hình sẽ chú ý nhiều hơn vào các đặc trưng có giá trị quá lớn mà bỏ qua những đặc trưng mang giá trị nhỏ hơn.

Tóm lại, khi xây dựng mô hình ở trên nhiều đặc trưng, nếu như mà đặc trưng có quá nhiều giá trị biến thiên thì ta cần phải có một bước tiền xử lý trước để đưa tất cả các dữ liệu của mọi đặc trưng về một kiểu theo phân phối chuẩn hoặc max-min. Một điểm ta cần phải chú ý đó chính là khi ta đã chuẩn hóa dữ liệu rồi thì khi dự đoán ta cũng phải chuẩn hóa đặc trưng đó.

4.3. So sánh Log-Likelihood giữa mô hình đầy đủ và đơn biến

Tương tự khi nói về hệ số hồi quy và phân tích đặc trưng nào có ý nghĩa thống kê, tại câu hỏi bài tập này em cũng chia ra làm hai trường hợp là không chuẩn hóa và chuẩn hóa dữ liệu. Phần này chủ yếu dùng để trình bày, không liên quan đến tập Test của mô hình đơn biến và đa biến nên sẽ sử dụng trên 248 mẫu dữ liệu để tính toán.

4.3.1. Mô hình đa biến nhưng không chuẩn hóa z-score

Giá trị Log-Likelihood của hai mô hình:

- Log-Likelihood của mô hình đơn biến (fbs): -171.4422 .
- Log-Likelihood của mô hình đa biến: -1193.1936 .

Cả hai mô hình đều không bật chức năng quy các dữ liệu của đặc trưng về phân phối chuẩn.

Từ giá trị Log-Likelihood trên thì ta có thể thấy, dù mô hình đơn biến với đặc trưng y học là chỉ số đường huyết là mô hình không đủ mạnh để có thể dự đoán bệnh tim nhưng giá trị Log-Likelihood của đơn biến trả về tốt hơn so với mô hình đa biến. Vì ta không chuẩn hóa dữ liệu theo phân phối chuẩn cho nên đa biến không có hội tụ trong khi đó thì đơn biến lại hội tụ dễ dàng hơn. Mô hình đa biến trường hợp không chuẩn hóa dữ liệu vẫn trả ra kết quả

dự đoán tốt hơn so với đơn biến nhưng giá trị Log-Likelihood cao vậy cho thấy mô hình đa biến này vẫn chưa phải là một mô hình tốt để có thể dự đoán.

4.3.2. Mô hình đa biến nhưng chuẩn hóa z-score

Giá trị Log-Likelihood của hai mô hình:

- Log-Likelihood của mô hình đơn biến (fbs): -171.4422 .
- Log-Likelihood của mô hình đa biến: -86.5227 .

Cả hai mô hình đều bật chức năng quy các dữ liệu của đặc trưng về phân phối chuẩn.

Ở trường hợp thứ hai sau khi chuẩn hóa dữ liệu về phân phối chuẩn, mô hình đơn biến vẫn cho ra giá trị tương đương với trường hợp một là -171.4422 và mô hình đơn biến nếu so với trường hợp không chuẩn hóa dữ liệu thì Gradient Descent hội tụ nhanh hơn nhiều lần. Điểm đặc biệt ở trường hợp này là mô hình đa biến khi sử dụng tất cả các đặc trưng y học thì Log-Likelihood của mô hình này đã giảm xuống đáng kể và giá trị hiện tại là -86.5227 . Việc chuẩn hóa dữ liệu là một lợi thế giúp cho mô hình đa biến có thể thu hẹp tất cả dữ liệu của các đặc trưng trở thành những giá trị cho mô hình học tốt hơn và giúp cho Gradient Descent hội tụ nhanh chóng hơn.

Ngoài ra, khi đối chiếu với Log-Likelihood của thư viện `statmodel.api` thì giá trị Log-Likelihood của thư viện khi sử dụng trên mô hình đa biến có giá trị là -86.523 . Nghĩa là sau khi chuẩn hóa dữ liệu thì mô hình đa biến dự đoán để đánh nhãn tốt hơn so với mô hình đơn biến và ta có thể dùng mô hình này để có thể dự đoán chính xác hơn so với mô hình đơn biến và mô hình đa biến phiên bản không chuẩn hóa dữ liệu theo phân phối chuẩn.

4.3.3. Nhận xét

Thông qua quá trình huấn luyện và kiểm tra về Log-Likelihood của cả hai mô hình đơn biến và đa biến thì ta có thể thấy như sau. Ở trường hợp một, khi không tiền xử lý dữ liệu trước thì mô hình đơn biến cho ra giá trị Log-Likelihood tốt hơn so với mô hình đa biến và mô hình đơn biến còn có thể hội tụ nhanh hơn so với mô hình đa biến. Sang tới trường hợp hai là cả hai mô hình đều có tiền xử lý dữ liệu trước thì mô hình đơn biến trước và sau khi phân phối chuẩn đều cho ra giá trị tương đương nhau trong khi mô hình đa biến sau khi đã chuẩn hóa dữ liệu thì giá trị Log-Likelihood của đa biến giảm xuống và có ra giá trị gần 0 hơn so với đơn biến. Ngoài ra, cả hai mô hình đều hội tụ và tính toán nhanh và tốt hơn. Nhưng nếu so thì mô hình đa biến sau khi đã chuẩn hóa dữ liệu là mô hình tốt hơn vì dữ liệu quy về phân phối chuẩn, tính toán và dự đoán chính xác hơn so với mô hình đơn biến, dù đơn biến cho ra giá trị Log-Likelihood cũng không quá thấp nhưng mô hình đơn biến là mô hình dự đoán không mạnh như em đã thực hiện ở trên, dự đoán cũng chỉ ở mức trung bình và gần với đường đứt nét đại diện cho ngẫu nhiên.

4.4. Đánh giá hiệu năng của mô hình đa biến

4.4.1. Chuẩn bị siêu tham số và tiêu chí đánh giá

Mô hình đa biến sử dụng tất cả đặc trưng y học được xây dựng với siêu tham số như sau:

- α (learning_rate) = 0.01.
- Số lần lặp (num_iters) = 50000.
- Sai số chấp nhận được để hội tụ (tolerance) = $1e - 5 = 0.00001$.
- Mô hình đa biến có sử dụng phân phối chuẩn (scale = True).

Mô hình sẽ được học ở trên file train.csv tuy nhiên chỉ học trên 198 mẫu (từ 1 $\rightarrow$ 198), 50 mẫu còn lại (từ 199 $\rightarrow$ 248) sẽ được dùng cho tập Valid nhằm kiểm tra hiệu năng của mô hình lần cuối trước khi cho mô hình sử dụng 50 mẫu nằm trong file test.xlsx. Mô hình sẽ được kiểm tra thông qua các tiêu chí:

- Accuracy (độ chính xác mà mô hình dự đoán với dữ liệu gốc).
- Cross-Validation (nhằm đánh giá độ thành công của mô hình và mất mát bao nhiêu).
- Confusion Matrix (phân tích xem mô hình đã dự đoán đúng bao nhiêu nhãn là khớp với nhãn gốc).
- Đường cong ROC và AUC (trực quan biểu đồ cho biết là mô hình đã dự đoán nhãn các dữ liệu là đúng hay sai nhiều hơn, có dự đoán được tổng quát, nghiêng về phía nào giữa hai nhãn đúng và sai).

Đây cũng chính là những siêu tham số và tiền xử lý dữ liệu mà em đã thiết lập cho mô hình đa biến để có thể trả lời câu hỏi bài tập số 9 và số 10, so sánh giữa việc không chuẩn hóa và chuẩn hóa dữ liệu khi nói về hệ số hồi quy và giá trị Log-Likelihood.

4.4.2. Đánh giá trên tập Valid

Sau khi cho mô hình đa biến học được 80% dữ liệu, kiểm tra xem là với 80% dữ liệu gốc, mô hình đã dự đoán chính xác 86.36%, mất mát là 0.3587. Đưa mô hình đó qua tập Valid thì mô hình dự đoán chính xác các nhãn là 86%, mất mát trên tập Valid là 0.3409.

Sau đó, thực hiện kiểm tra mô hình đơn biến theo KFold, kiểm tra với 10 lần khác nhau thì kết quả sai số về độ chính xác và mất mát của mô hình đa biến là:

- CV Loss: 0.4158 ± 0.1156
- CV Acc: 0.8145 ± 0.0674

Kết quả về độ chính xác và mất mát của mô hình đa biến trên hai tập là tập Train và Valid đều ở trong phạm vi của CV Acc và CV Loss chứng tỏ mô hình đa biến sử dụng tất cả đặc

trung y học có thể học tổng quát, không phải chỉ thuộc Pattern để phân tích và dự đoán, cũng cho thấy được là mô hình không bị tình trạng Overfitting và nhận diện các mẫu tốt.

Tuy nhiên, chỉ với độ chính xác về dự đoán thì không phải là tiêu chí chính xác mà ta sẽ xem là trên tập Valid, mô hình đã thực sự dự đoán như thế nào thông qua Confusion Matrix. Trên tập Valid thì mô hình đã dự đoán như sau, lớp bị bệnh tim được chẩn đoán là Positive và lớp không bị bệnh tim là Negative.

Thực tế/Dự đoán	Có bệnh (1)	Không bệnh (0)
Có bệnh (1)	19 (True Positive)	5 (False Negative)
Không bệnh (0)	2 (False Positive)	24 (True Negative)


Bảng 12: Bảng chéo cho biết dự đoán và thực tế của mô hình đa biến

Trong đó:

- True Positive = 19: thực tế là có bệnh và dự đoán cũng là có bệnh.
- False Positive = 2: thực tế là không bệnh nhưng dự đoán là có bệnh. (sai lầm loại I).
- False Negative = 5: thực tế có bệnh nhưng dự đoán là không bệnh. (sai lầm loại II).
- True Negative = 24: thực tế không bệnh và dự đoán không bệnh.
- Mô hình dự đoán đúng là $19 + 24 = 43$ bệnh nhân, tỉ lệ thành công là 86%
- Trong việc dự đoán có bệnh thì Precision = 0.9048, Recall = 0.7917.

So với mô hình đơn biến thì mô hình đa biến cho ra kết quả tốt hơn khi mà độ chính xác đoán đúng là 86% ở trên tập Valid, cả hai điểm về Precision và Recall của mô hình đa biến rất cao cho nên là điểm F1-score của mô hình đa biến cũng cao với giá trị là 0.8444. Chỉ số F-score cao này cho thấy là khi kiểm tra, mô hình đa biến học tốt và có thể phân loại tốt hơn so với mô hình đơn biến nhưng chỉ dùng một đặc trưng là chỉ số đường huyết để dự đoán. Thay vì như mô hình đơn biến là dự đoán có phần may rủi thì mô hình đa biến có thêm nhiều thông tin để có thể đánh nhãn chính xác hơn.

Cuối cùng là chỉ số AUC và ROC của mô hình đa biến thì ta có thể quan sát biểu đồ dưới đây:



Hình 11: Chỉ số AUC và đường cong ROC trên tập Valid của mô hình đa biến

Chỉ số AUC ghi nhận từ mô hình đa biến trên tập Valid là 0.9343, đây là con số cao đánh giá cho thấy là trên tập Valid hiện tại, mô hình đa biến dự đoán để đánh nhãn cho dữ liệu trực quan và tốt hơn rất nhiều khi so sánh với mô hình đơn biến. Đường cong ROC của mô hình đa biến cách xa đường nét đứt đại diện cho dự đoán ngẫu nhiên và lệch về bên trái nhiều hơn cho thấy là mô hình dự đoán đúng tốt và ổn định nếu so sánh với mô hình đơn biến đã được xét ở trên. Mô hình đa biến lần này là sử dụng hết tất cả đặc trưng y học hiện có cho nên là mô hình có nhiều thông tin để có thể kiểm tra một bệnh nhân xem là người đó có huyết áp như nào, huyết áp lúc nghỉ ra sao,... Vì có nhiều thông tin được tiếp nhận và thông tin đã được chuẩn hóa cho nên việc tính toán và dự đoán của mô hình đa biến được tốt hơn và chính xác cao hơn.

4.4.3. Đánh giá mô hình dựa trên tập Test

Khi ta sử dụng mô hình đa biến trên tập Test thì ta ghi nhận được kết quả như sau:

- Accuracy: $0.8400 = 84\%$.
 - Loss: 0.3723.
- ⇒ So sánh với Cross-Validation KFold về Accuracy và Loss thì ta thấy được là mô hình đa biến không bị Overfitting ở trên tập Test.


Xét tới Confusion Matrix thì ta có bảng chéo dự đoán như sau:

Thực tế/Dự đoán	Có bệnh (1)	Không bệnh (0)
Có bệnh (1)	16 (True Positive)	4 (False Negative)
Không bệnh (0)	4 (False Positive)	26 (True Negative)

Trong đó:

- True Positive = 16: thực tế là có bệnh và dự đoán cũng là có bệnh.
- False Positive = 4: thực tế là không bệnh nhưng dự đoán là có bệnh. (sai lầm loại I).
- False Negative = 4: thực tế có bệnh nhưng dự đoán là không bệnh. (sai lầm loại II).
- True Negative = 26: thực tế không bệnh và dự đoán không bệnh.
- Mô hình dự đoán đúng là $16 + 26 = 42$ bệnh nhân, tỉ lệ thành công là 84%
- Trong việc dự đoán có bệnh thì Precision = 0.8, Recall = 0.8.

Khi hoạt động ở trên tập Test, Precision và Recall của mô hình đa biến trả ra kết quả khá cao và do cả hai điểm đều cao cho nên là điểm F1-score của mô hình trên tập Test cũng cao với giá trị ghi nhận là 0.8. Điều này cho thấy là mô hình đa biến là một mô hình dự đoán tốt, mô hình đã được huấn luyện trên nhiều thông tin nhằm đưa ra dự đoán để phân loại chính xác bệnh nhân nào mắc bệnh tim và bệnh nhân nào không bị mắc bệnh tim. Bên cạnh đó, mô hình đa biến được học ở trên những hệ số, sai số nhỏ hơn được học do các dữ liệu của từng đặc trưng đã được quy về thành phân phối chuẩn cho nên mô hình có thể dự đoán nhanh và chính xác như trên.



Hình 12: Chỉ số AUC và đường ROC của mô hình đa biến trên tập Test

Dựa trên đường cong ROC ở hình trên, ta thấy là mô hình đa biến có khả năng phân biệt tốt giữa hai nhóm đối tượng là nhóm bị bệnh tim và nhóm không bị bệnh tim. Đường ROC cao hơn hẳn so với đường chéo ngẫu nhiên cũng cho thấy mô hình học được mối quan hệ có ý nghĩa từ dữ liệu. Giá trị AUC trên tập Test của mô hình đa biến là 0.8733, nằm trong ngưỡng 0.8-0.9 là một mức dự báo tốt. Điều này chứng tỏ mô hình có thể phân loại chính xác phần lớn trường hợp có bệnh và không bệnh.

4.4.4. Nhận xét

Khác với mô hình đơn biến chỉ sử dụng chỉ số đường huyết làm thông tin để dự đoán thì mô hình đa biến có thể phức tạp hơn so với mô hình đơn biến nhưng việc sử dụng nhiều đặc trưng y học kết hợp lại với nhau đã giúp cho mô hình đa biến có thể dự đoán và đánh nhãn chính xác nhiều hơn nếu so sánh về độ chính xác với mô hình đơn biến. Nhờ tích hợp nhiều đặc trưng lại nên mô hình đa biến giảm nguy cơ của việc đoán ngẫu nhiên nhằm cải thiện độ chính xác và khả năng phân loại.

Khi sử dụng mô hình đa biến, ta còn có thể xác định xem là biến nào thực sự có ý nghĩa trong việc dự đoán bệnh tim thay vì chỉ dùng một đặc trưng duy nhất. Điều này cũng thực tế ở trong y học vì bệnh tim nói riêng hay những bệnh khác nói chung không chỉ phụ thuộc vào duy nhất một đặc trưng mà là kết hợp thông tin của những đặc trưng khác. Cho nên, mô hình đa biến phản ánh tình huống thực tế tốt hơn so với mô hình đơn biến và có giá trị ứng dụng hơn trong việc dự đoán bệnh nhân có bị bệnh hay không.

Trong ngữ cảnh của bài toán này, em đánh giá cả hai mô hình thông qua các tiêu chí là Accuracy để nói về độ chính xác, Cross-Validation cho việc lập một khoảng xem là mô hình có bị trường hợp Overfitting hay không, Confusion Matrix để làm rõ hơn cho độ chính xác và chỉ số AUC và ROC. Qua quá trình huấn luyện cả hai mô hình đơn biến và đa biến thì chỉ số AUC là chỉ số quan trọng nhất vì:

- Accuracy (độ chính xác): cho biết tỉ lệ dự đoán đúng trên toàn bộ dữ liệu. Tuy nhiên thì dữ liệu có thể bị mất cân bằng giữa nhóm bệnh và không bệnh cho nên phải kết hợp tiêu chí này với tiêu chí Confusion Matrix nhằm tính toán xem là mô hình đã thực sự dự đoán bệnh nhân như thế nào so với thực tế.
- Đường cong ROC và chỉ số AUC thì cho ta đánh giá toàn diện hơn vì ROC thể hiện mối quan hệ giữa nhóm bệnh và không bệnh trên mọi ngưỡng dự đoán. AUC càng cao thì mô hình càng có khả năng phân biệt tốt giữa nhóm bệnh và không bệnh. Ở kết quả của mô hình đa biến AUC đạt giá trị 0.87 cho thấy khả năng của mô hình dự đoán khá tốt và tin cậy. Chỉ số này cũng phản ánh năng lực phân loại tổng thể, không phụ thuộc vào một ngưỡng xác suất cụ thể và giảm nguy cơ bỏ sót bệnh nhân.

4.5. Hạn chế của hồi quy Logistic

4.5.1. Hạn chế

Trong tập dữ liệu trên, nhiều đặc trưng có xu hướng liên quan chặt chẽ với nhau. Ví dụ, tuổi (age) thường đi kèm với huyết áp lúc nghỉ (trestbps) và cholesterol trong máu (chol); loại đau ngực (cp) có thể liên hệ với biến “exang” (đau ngực khi gắng sức); hoặc “thal” và “slope” đều phản ánh các khía cạnh liên quan đến bài kiểm tra gắng sức tim. Khi các biến đầu vào tương quan mạnh với nhau, hiện tượng đa cộng tuyến có thể xuất hiện.

Hiện tượng đa cộng tuyến có thể gây ra một số hệ quả như sau:

- Hệ số hồi quy không ổn định: các giá trị ước lượng của mô hình thay đổi mạnh khi thêm hoặc bớt vài quan sát trong dữ liệu.
- Độ tin cậy giảm: sai số chuẩn của hệ số trở nên lớn, làm cho p – value tăng cao và dẫn đến việc khó xác định biến nào thực sự có ý nghĩa thống kê.
- Khả năng diễn giải kém: thay vì phản ánh tác động thực sự của từng biến, mô hình Logistic có thể chia nhỏ tác động giữa các biến tương quan. Ví dụ, nếu cả cholesterol và huyết áp cùng liên quan đến bệnh tim, mô hình có thể không rõ ràng biến nào là yếu tố chính, mà hệ số của chúng sẽ phụ thuộc vào nhau.

4.5.2. Đề xuất giải pháp

Trong bài toán hồi quy logistic cơ bản, khi dữ liệu có hiện tượng đa cộng tuyến, các hệ số ước lượng có thể dao động lớn và thiếu ổn định, khiến việc giải thích kết quả trở nên khó khăn. Để khắc phục, ta có thể áp dụng **regularization** – một kỹ thuật bổ sung thêm “hình phạt” (penalty) vào hàm mất mát, nhằm kiểm soát độ lớn của các hệ số. Có hai dạng phổ biến:

- L1 regularization (Lasso Logistic Regression): Hình phạt được cộng thêm là tổng giá trị tuyệt đối của các hệ số, giúp một số hệ số có thể bị triệt tiêu hoàn toàn về 0. Vì thế, Lasso vừa giúp giảm đa cộng tuyến, vừa làm cho mô hình gọn nhẹ và dễ tính toán, diễn giải hơn.
- L2 regularization (Ridge Logistic Regression): Hình phạt (penalty) là tổng bình phương của các hệ số. Khác với Lasso, Ridge không triệt tiêu hệ số về 0 mà thu nhỏ các hệ số lại, làm giảm dao động và giúp mô hình ổn định hơn. Phương pháp này hữu ích khi tất cả các biến đều có ý nghĩa, quan hệ chặt chẽ với nhau.

5 Tài liệu tham khảo

- [1] N. T. Tuấn, "Logistic Regression," in *Deep Learning Cơ Bản*, Ha Noi, Nguyễn Thanh Tuấn, 2020, pp. 65-78.
- [2] Đ. T. Giang, "Github/ml-glossary-vn," 17 01 2022. [Online]. Available: https://github.com/trgiangdo/ml-glossary-vn/blob/main/docs/logistic_regression_vn.rst. [Accessed 20 8 2025].
- [3] J. Shakir, "Github/Logistic_Regression," 13 7 2018. [Online]. Available: https://github.com/JuzerShakir/Logistic_Regression/blob/master/README.md. [Accessed 20 8 2025].
- [4] Developer Google, "Google for Developers," [Online]. Available: <https://developers.google.com/machine-learning/crash-course/logistic-regression/sigmoid-function>. [Accessed 20 08 2025].
- [5] Google Developers, "Google for Developers," [Online]. Available: <https://developers.google.com/machine-learning/crash-course/logistic-regression/loss-regularization>. [Accessed 20 08 2025].
- [6] NeuralNine, Director, *Logistic Regression From Scratch in Python (Mathematical)*. [Film]. Youtube, 2025.
- [7] Developers Google, "Google For Developer," [Online]. Available: <https://developers.google.com/machine-learning/crash-course/numerical-data/normalization>. [Accessed 20 08 2025].
- [8] GeeksForGeeks, "GeeksForGeeks," 02 08 2025. [Online]. Available: <https://www.geeksforgeeks.org/machine-learning/regularization-in-machine-learning/>. [Accessed 20 08 2025].

- [9] A. Nagpal, "builtin," 05 01 2022. [Online]. Available: <https://builtin.com/data-science/l2-regularization>. [Accessed 20 08 2025].
- D. Bourgin, "numpy-ml," 24 12 2021. [Online]. Available: https://numpy-ml.readthedocs.io/en/latest/numpy_ml.linear_models.lm.html. [Accessed 20 08 2025].
- [10]